

DATA WRANGLING

Prof. Dr. Wilson Tarantin Junior

MBAUSP ESALQ

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização.

Lei nº 9610/98

Data Wrangling

- O que é data wrangling?
 - É o processo de transformar a base de dados de sua estrutura original (dados brutos) para uma nova estrutura que permita a adequada extração de informações
 - > Raramente os dados brutos estão disponíveis na estrutura mais adequada para as análises
 - Portanto, é uma etapa de preparação, organização, manipulação dos bancos de dados
 - > Ocorre antes da análise exploratória dos dados, criação de gráficos e modelagem
 - > Quanto melhor for a etapa de data wrangling, melhores serão os dados e maior tende a ser a qualidade das informações extraídas
 - > Não é uma atividade padronizada: em função do contexto, diferentes etapas serão aplicadas



Data Wrangling

- Etapas do processo de tratamento dos dados
 - Coleta e importação: os dados podem ser provenientes de fontes diversas
 - > Exemplos: planilhas de Excel e CSV, API, SQL. Em alguns casos, é possível automatizar a coleta
 - Junção: os dados provenientes das várias fontes precisam ser reorganizados para que seja possível a união de observações e variáveis
 - > Em muitos casos, exige variáveis que sejam "chaves" para o relacionamento entre tabelas
 - Transformação: contempla as diversas etapas de modificação dos dados
 - > Exemplos: limpeza dos dados, criação e alteração de variáveis, seleções, agregações, resumos...



Data Wrangling

6 Steps of Data Wrangling



DISCOVERY:

Familiarizing yourself with data to conceptualize how you might employ it



STRUCTURING:

Transforming raw data to readily use it



CLEANING:

Removing inherent errors in data that might distort your analysis



ENRICHING:

Determining whether to enrich or augment your existing data



VERIFYING:

Confirming your data is consistent and high quality



PUBLISHING:

Making your data available for analysis

Fonte: https://online.hbs.edu/blog/post/data-wrangling



Python

- Biblioteca para data wrangling
 - Embora muitas bibliotecas sejam úteis no processo de manipulação de dados, utilizaremos o pandas como ferramenta principal
 - > Manual do usuário: https://pandas.pydata.org/docs/user_guide/index.html
 - > Material de consulta: https://pandas.pydata.org/Pandas Cheat Sheet.pdf



MBALLSP

Obrigado!

Wilson Tarantin Junior linkedin.com/in/wilson-tarantin-junior-359476190